

机器学习上机报告

林远钊 1700010672

2019 年 4 月 12 日

目录

1	支持向量机 Review	2
2	python 实现	3
2.1	数据格式	3
2.2	实现思路	3
2.3	支持向量分类 SVC	3
2.4	关于支持向量数目的讨论	5
2.5	支持向量回归 SVR	5
3	对支持向量的优化	5
3.1	聚类 (Clustering) 简介	5
3.2	具体试验	6

1 支持向量机 Review

基本介绍 支持向量机 (Support Vector Machines, SVM) 是一种监督学习的方法，可用于分类，回归和异常值探查。其优点包括：在高维空间效率较高，在维数高或样本数时仍然有效，可以用总体训练数据中的一部分（称为“支持向量”）的一部分来生成决策函数（这意味着它的存储性能是比较好的）；而它的缺点有：如果特征的数目远大于样本的数目，那么合理的选择核函数和正则化项是重要而困难的，而且支持向量机不直接给出概率估计。

实现工具 本次上机作业中主要通过 scikit-learn 这一 python 包来实现支持向量机。在使用之前需要对其进行一定的了解和学习。

sklearn(scikit-learn 包的常用缩写) 中有专门的 svm 模块，可以通过命令

```
1 from sklearn import svm
```

导入该模块,本次上机中使用到的主要是其中的支持向量分类器 (SVC) 和支持向量回归 (SVR)。

2 python 实现

由于本次上机中使用了包，大可把其作为黑箱，其中具体实现细节不必深究。

2.1 数据格式

同上一次对数据的处理一样，在处理书中所给表格 3.0 α 中的数据时，我们将数据处理为.csv 文件形式，第一行为数据的属性集合，以下每行对应一个数据在这些属性上的取值。好瓜的标签（label）记作 1，坏瓜则记为-1。

2.2 实现思路

首先需要先将所给数据转化成易于处理的形式。这里我们利用 numpy 和 pandas 包中的方法进行简单的转化，相应定义一个信息处理函数 loadData(filename)

```

1  """默认 csv 文件第一行是列属性，以下每行是训练数据
2  并且数据的最后一列必然是数据的 label"""
3  frame = pd.read_csv(filename)#读为 DataFrame 格式
4  labels = frame['label']#获取标记
5  attrset = list(frame.columns)
6  attrset.remove('label')
7  dataset = list(frame.values)
8  for i in range(frame.shape[0]):#遍历所有数据
9      dataset[i] = list(dataset[i])
10     dataset[i].pop()
11 return dataset, list(labels), attrset
12 #返回数据集 (Dataset) 和标记集 (List) 和属性集

```

2.3 支持向量分类 SVC

为了回答 6.2 中的问题，分别使用线性核和高斯核训练一个 SVM

```

1  dataset, labels, attrset = loadData('data3.0alpha.csv')
2  kernel = ('linear', 'rbf')
3  clf1 = svm.SVC(kernel='linear')
4  clf2 = svm.SVC(kernel='rbf', gamma='scale')
5
6  ans = (clf1.fit(dataset, labels), clf2.fit(dataset, labels))
7
8  for i in range(2):
9      svcs = ans[i].support_vectors_

```

```
10     print('核函数为',kernel[i],'的支持向量为：')
11     for j in range(len(svs)):
12         print(svs[j])
13     print('支持向量的个数为',len(svs))
```

输出结果依次被记录在以下的两个图中（已进行可视化处理）。附件中有原图和纯数据的输出。

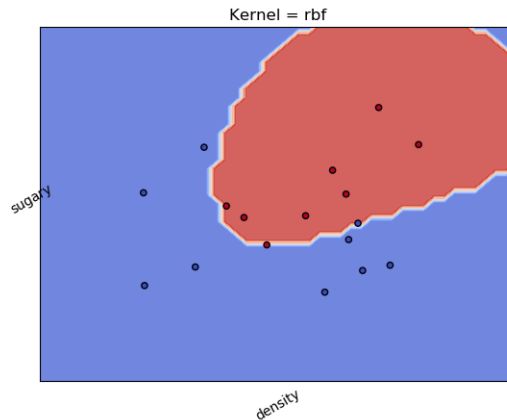


图 1: RBF

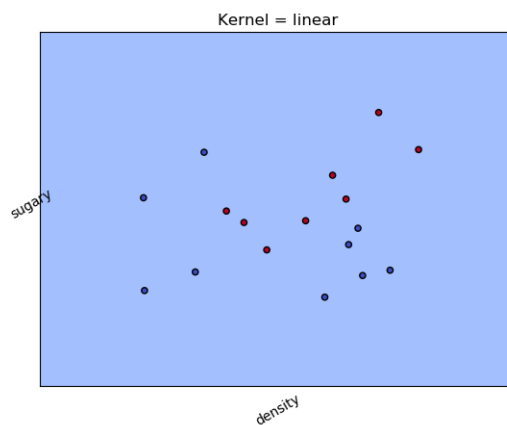


图 2: Linear

可以看到高斯核的预测性质似乎更为合理，而线性核则只能做到将全平面分为一类，这说明线性核对于这个问题是极其不适用的。其中线性核的支持向量是 16 个，而高斯核支持向量是 17 个。（ps：私以为本题中数据数量过少应该也是分类效果不佳的原因之一）

2.4 关于支持向量数目的讨论

显然，总样本数只有 17 个，习得的支持向量数却分别有 16、17 个，这件事情不是那么的令人满意。笔者在这个问题上犹豫了很久，最后发现如果将参数 `max_iter` 设定为一些值（如 1），可以显著减少支持向量个数（减少到只有 2 个）。原因是 `max_iter` 是 SMO 算法的迭代次数，当不限制迭代次数时，训练出的模型会和给定样本更加贴合（当然有过拟合的风险），介于此，在上面并未刻意调整支持向量个数，而保留了最开始的结果。

2.5 支持向量回归 SVR

为了回答 6.8 中的问题，调用 `svm.SVR` 类即可得

```
1 frame = pd.read_csv('data3.0alpha.csv')
2 labels = frame['label']
3 X = frame['密度']
4 Xm = []
5 for x in X:
6     Xm.append([x])
7 y = frame['含糖率']
8 clf = svm.SVR(gamma='scale',kernel='rbf')
9 clf.fit(Xm, y)
```

即可得到 SVR。

3 对支持向量的优化

基于一个朴素的想法：在进行支持向量分类前先对数据进行某种预处理，使得样本点中有极大相似性的部分被合理地替代，在这一步处理便尽量不丢失信息地减少样本点的数量，尤其是非支持向量的个数，由此减少支持向量的数量而不显著地降低 SVM 的泛化性能。

具体实现中，采用聚类 (Cluster) 的技术来达到以上所述的目的，并且以下通过对 iris 数据集的分析来粗略地了解该技术的效果。

3.1 聚类 (Clustering) 简介

聚类是一种无监督学习的方法。

在 `sklearn` 中，每个聚类算法主要都有两种形式，一种是一个类，其中的方法 `fit` 可以习得训练数据的聚类；亦或者是一个函数，在给定训练数据时，返回一个整数标记的数组对应着不同的聚类。简单地，以下采用 K-均值法进行聚类学习。

基本思想是：在给定数据后，将数据依原类别分开，并对分开后的若干组数据分别做 KMeans 聚类学习，得到学习后的每组聚类均值点。以这些均值点作为新的数据依据进行学习。当然，以

上聚类学习学得类的数目是一个应当调整的参数。

3.2 具体试验

以下将以 iris 数据集为例，观察之前策略的学习效果。

在 sklearn 官方文档中给出了对 iris 数据集分别以四种不同核函数学习的结果如下图所示。




图 3: iris-before

而 iris 数据集中共有 150 个数据，每种类别的数据各有 50 个，因而对每一个类别中的数据进行聚类学习，保留 10 个聚类均值数据作为新的数据依据进行学习。得到新的结果如下。

可以看到习得的模型并无显著改变且显然支持向量数将减少（样本数减少到之前的 1/10）。以上便是 6.10 的解答。

附件中包含了报告中所有的图片及使用的所有源代码。

(PS: Latex 水平比较差，最后图片部分排版炸了 qwq 助教见谅)

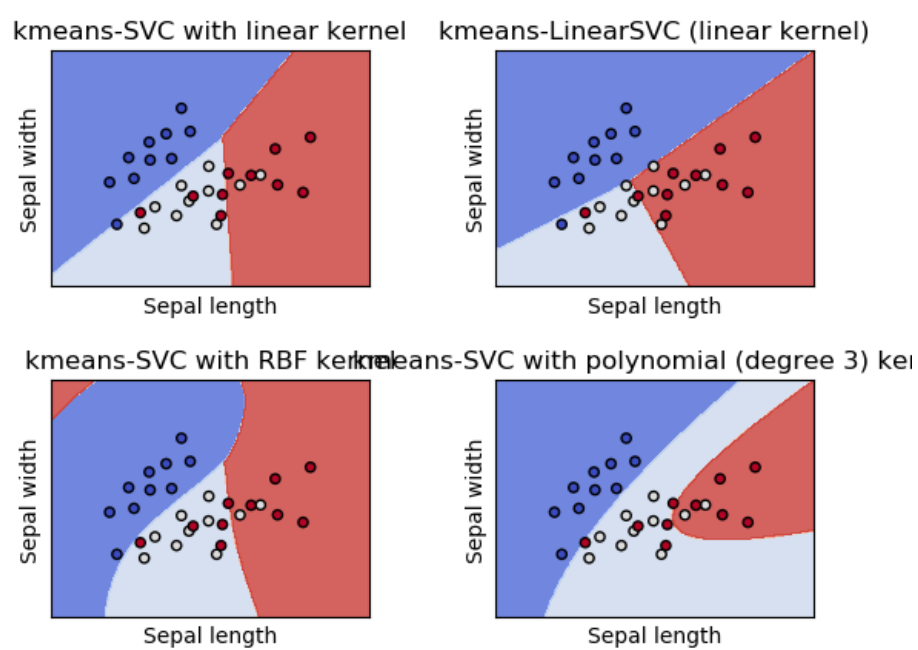


图 4: iris-after